

多任务 BERT 模型在校园舆情监测中的应用

杨 洵

福建农业职业技术学院信息工程学院 福建 福州 350303

【摘要】针对高校校园舆情管理中传统人工分析效率低、语义理解能力不足的问题,本研究提出了一种基于 Transformer 的双向编码器表示(BERT)的多任务舆情监测系统。该系统对学生每日校园评论进行情感分析(正面/负面)和主题分类(8类校园主题)。通过 PyTorch 框架微调 bert-base-chinese 模型,构建多任务学习框架,优化复杂语义处理能力。系统采用快速应用程序编程接口(FastAPI)后端提供预测接口,Streamlit 前端实现评论输入与结果展示,SQLite 数据库存储分析结果。验证实验在 5 826 条校园评论数据集上进行,情感分类准确率达 92.3%,主题分类准确率达 87.6%。通过情感分布饼图和主题词云可视化舆情趋势,为高校管理者提供数据支持。该系统具有高准确性、实时交互能力和可扩展性,可为智慧校园管理提供技术参考。

【关键词】神经网络;人工智能;语义分类**【中图分类号】**TP181**【文献标识码】**A

DOI:10.16009/j.issn.1009-5624.2026.01.035

0 引言

随着信息化和社交媒体的快速发展,高校学生通过校园论坛、社交平台等渠道表达对课程、活动及校园生活的看法。这些评论不仅蕴含着丰富的情感信息和主题内容,还对优化教学与管理具有重要价值。然而,传统人工舆情分析方法效率低下,难以应对海量数据和复杂语义的处理需求^[1]。近年来,自然语言处理技术的进步为舆情分析提供了新机遇。基于 Transformer 的双向编码器表示(bidirectional encoder representations from transformers, BERT)模型因其强大的双向语义理解能力,在情感分析和主题分类中表现出色^[2]。多任务学习框架通过共享底层表示提升模型效率,已被广泛应用于自然语言处理任务。然而,现有校园舆情研究多聚焦单一任务,如单一的情感分析或单一的主题建模,缺乏多任务联合分析和实时交互功能^[3]。为解决上述问题,本文设计并实现了一种基于 BERT 的多任务舆情监测系统,针对学生每日评论进行情感分析(正面/负面)和主题分类(抱怨反馈、学术相关等 8 类主题)。系统采用 PyTorch 框架,基于 10 000 条人工标注的训练数据集微调 bert-base-chinese 模型,结合快速应用程序编程接口(fast application programming interface, FastAPI)、Streamlit 和 SQLite 技术,实现实时预测、结果存储和可视化展示。通过 5 826 条测试数据集实验验证了系统的高准确性和实用性,为高校管理者提供数据支持,助力智慧校园管理^[4-5]。

1 多任务 BERT 模型概述

1.1 BERT 模型原理及特点

BERT 是一种基于 Transformer 架构的预训练模型,通过双向上下文建模捕获深层语义表示^[6]。其核心是自注意力机制,能够处理长距离依赖关系,适用于复杂语义场

景。bert-base-chinese 模型针对中文优化,包含 12 层 Transformer 编码器、768 维隐藏层和约 21 128 个词汇,支持中文文本的分词和语义分析。BERT 通过掩码语言模型和下一句预测任务进行预训练,增强对语境的理解能力,相较于传统词向量模型具有更强的泛化性^[7]。

1.2 多任务学习在舆情监测中的优势

多任务学习通过共享底层表示,同时优化多个任务,例如,情感分析和主题分类,从而减少模型参数冗余,提升训练效率和泛化能力。在校园舆情监测中,现有校园舆情研究多聚焦单一任务,如单一的情感分析或单一的主题建模,缺乏联合情感分类和主题分类。相较于单一任务模型,多任务学习能更好地处理多样化的校园评论数据,适应复杂场景。

1.3 学生校园评论的情感分析与主题分类需求分析

校园评论涵盖课程评价、活动反馈、社交互动等多方面,需识别正面/负面情感及校园生活主题。功能需求包括:①实时预测。用户输入评论,系统输出情感和主题分类结果。②历史数据管理。支持查询、编辑、删除历史评论及关键词搜索。③性能评估。内置评估接口,计算准确率、精确率、召回率和 F_1 值。④可视化展示。通过饼图和词云直观呈现舆情趋势。⑤用户认证。基于 JSON (JavaScript object notation) 网络令牌实现登录和权限管理,区分管理员和普通用户角色。

2 基于 BERT 的多任务舆情监测系统设计

2.1 数据预处理

本系统的数据集分为训练数据集(campus_emo_utf8.csv)和测试数据集(campus-emo_sim.csv),分别包含 10 000 条数据和 5 826 条评论。这些数据是使用 Python 结合 Requests 和 BeautifulSoup 框架从北京未名论坛爬取的评论,时间跨度为 2023—2024 年。数据清洗移除无效字符、表情符号和重复内容,以确保数据质量。人工标注由 10 名在校学生和教师完成,分为初标和复核组,标注情感(正面/负面)和 8 类主题,分别为:抱怨反馈、学术相关、人际交往、生活娱乐、互助求助、兴趣爱好、校园活动与事件、资源

基金项目:福建农业职业技术学院 2025 年校级科研基金自然科学类一般项目(ZZXYB11525008)。

作者简介:杨洵(1983—),男,福建南平人,硕士,工程师,研究方向:人工智能、数据库技术。

交易,大致涵盖校园话题的各方面,各类别占比约 12.5%。随机抽检 10%数据,移除噪声,最终标注完成率达 99%。

数据预处理包括以下步骤:①分词,使用 BertTokenizer 进行分词,添加[CLS]和[SEP]标记,最大序列长度为 128。②标签编码,主题标签通过 LabelEncoder 转换为 0~7 的数值形式。③数据集分割,按 8:2 的比例分层分割为训练集(8 000 条)和验证集(2 000 条)。④批处理,创建批处理迭代器,每批次 16 个样本,以优化训练效率^[8]。

2.2 多任务学习框架设计

多任务 BERT 模型基于 bert-base-chinese,结构包括:①共享 BERT 层,提取通用语义表示,输出 768 维隐藏状态。②Dropout 层,丢弃率为 0.1,防止过拟合。③情感分类头,全连接层,映射到 2 维情感类别(正面/负面)。④主题分类头,全连接层,映射到 8 维主题类别。

损失函数为情感分类和主题分类的交叉熵损失之和($L=L_1+L_2$)。训练采用 AdamW 优化器,学习率为 2×10^{-5} ,结合线性 warmup(前 10%步长)和早停机制(验证集损失连续 3 个周期无改善则停止)。训练在 Google Colab 的 NVIDIA T4 图形处理单元(graphics processing unit,GPU)上进行,共 3 个历元(epoch),耗时约 45~60 min。

2.3 情感分析与主题分类算法实现

情感分析将评论分类为正面或负面,主题分类识别

8 类主题。训练流程包括:①数据加载,读取 campus_emo_utf8.csv,转换为 PyTorch 张量。②前向传播,BERT 模型输出情感和主题分类。③损失计算,联合优化情感和主题任务的损失。④模型保存,训练后保存模型权重(multi_task_bert_model.pth)和分词器(multi_task_bert_tokenizer)。⑤推理阶段,输入文本通过分词器编码,模型输出数字标签并映射回原始类别,例如,情感分类为“正面”或主题分类为“学术相关”。

3 校园舆情监测系统的实现与可视化

3.1 系统架构设计

系统架构如图 1 所示,包括以下模块。

- (1)数据输入模块:Streamlit 前端支持用户输入评论,并调用 FastAPI 后端的/predict 接口。
- (2)模型推理模块:加载训练好的 BERT 模型,执行情感和主题预测。
- (3)数据存储模块:基于 SQLite 数据库,表名为 comments,字段包括 id、text、sentiment、theme 和 create_at,用于存储预测结果。
- (4)可视化模块:采用 Matplotlib 生成情感分布饼图,采用 WordCloud 和 jieba 生成主题词云。
- (5)硬件要求: Intel i5 中央处理器、8 GB 内存、NVIDIA GTX 1060 GPU(支持计算统一设备架构 11.8+深度学习神经网络库)。软件环境:Windows 11,Python 3.8+。




图 1 系统架构

3.2 情感分布饼图生成与分析

验证测试数据集采用 campus-emo_sim.csv, 共 5 826 条评论。使用 Matplotlib 生成情感分布饼图, 展示正面/负面比例。验证结果显示, 正面 45%、负面 55%, 与采集测试数据时的人工标注比例相符, 证明了 BERT 模型的情感分类性能良好^[8]。

3.3 主题词云构建及展示

测试库数据集在进行分类之后, 结合 jieba 分词和 WordCloud 库生成主题词云, 字体大小反映词频。例如, “课堂纪律”的高频出现, 提示课堂纪律需要规范; “作业难”“听不懂”在抱怨反馈主题中高频出现, 提示教师需优化课程设计。通过词云分析, 管理者可快速捕捉学生的关注焦点。

3.4 数据支持与决策应用

系统通过可视化结果为高校管理者提供数据支持。例如, 分析显示: 学生对课程难度的负面反馈集中于“作业量大”, 提示管理者可调整作业设计; 社团活动相关评论多为正面, 提示可增加类似活动。系统支持实时预测和历史数据查询(如关键词搜索“课程”), 并可扩展至学生心理健康监测。例如, 通过分析负面评论中的高频词(如“压力”“焦虑”), 可识别潜在心理问题, 辅助心理咨询工作。系统具有可扩展性, 可应用于其他社交媒体场景, 如微博或微信公众号。

4 系统评估与实验结果分析

4.1 实验设计与指标选择

验证实验在 campus-emo_sim.csv 测试集(5 826 条评论)上进行。评估指标包括以下方面。

- (1) 准确率: 正确预测样本比例。
- (2) 精确率: 预测正类中实际正类的比例。
- (3) 召回率: 实际正类中正确预测的比例。
- (4) F_1 值: 精确率和召回率的调和平均数。

测试环境: Windows 11, Python 3.8+, 后端 FastAPI 通过 `uvicorn main:app --host 0.0.0.0 --port 8000` 启动, 前端 Streamlit 通过 `streamlit run app.py` 运行。

4.2 情感分析与主题分类性能评估

由表 1 可知, 情感分类的准确率为 92.3%, 主题分类的准确率为 87.6%, 准确率表现良好。表 2 展示了情感分类在测试数据集上的详细指标, 反映了模型在二分类任务上的高性能。这得益于情感标签的二分类特性以及 BERT 对情感语义的强表示能力。如表 3 所示, “资源交易”和“校园活动与事件” F_1 值相较于其他 F_1 值较低, 可能因样本量少(200~500 条)或语义复杂。错误分析显示, 部分学术相关评论因语义多样(如“课程有趣但作业难”)被误分类为抱怨反馈, 提示未来需引入领域特定预训练模型。

4.3 高校管理者决策效果评估

系统通过可视化分析帮助管理者识别舆情趋势。例

表 1 汇总分类报告结果 %

类别	准确率
情感分类	92.3
主题分类	87.6

表 2 情感分类报告

项目	精确率	召回率	F_1
正面	0.925	0.918	0.921
负面	0.921	0.925	0.923

表 3 主题分类报告

项目	精确率	召回率	F_1
互助求助	0.888 9	1.000 0	0.941 2
人际交往	1.000 0	1.000 0	1.000 0
兴趣爱好	0.964 3	0.964 3	0.964 3
抱怨反馈	0.960 5	1.000 0	0.979 9
学术相关	1.000 0	0.833 3	0.909 1
校园活动与事件	1.000 0	0.812 5	0.896 6
生活娱乐	1.000 0	0.909 1	0.952 4
资源交易	0.900 0	0.900 0	0.900 0

如, 饼图显示 55% 的负面情感, 词云突出“作业难”“课程压力”, 提示需调整课程设计。实时预测功能支持即时输入评论, 如“这门课作业太难”被正确分类为负面情感和学术相关主题。历史数据查询功能便于跟踪舆情变化, 如搜索“社团”可查看相关评论的趋势。系统还可辅助心理健康监测, 通过分析负面评论中的“压力”“焦虑”等词, 识别潜在问题, 支持精准干预。

5 结语

本研究基于 BERT 的多任务舆情监测系统实现了校园评论的情感分析和主题分类。经过验证集验证, 情感分类的准确率为 92.3%, 主题分类的准确率为 87.6%。通过情感分布饼图和主题词云, 系统直观呈现舆情趋势, 为高校管理者提供数据支持, 助力优化教学和活动安排。本系统具有实时交互、可扩展性和高准确性, 未来可从以下方向改进: ①领域预训练, 基于校园评论数据进行自适应预训练, 提升模型适应性。②细粒度情感分析, 扩展情感标签为多类别(如满意、失望、愤怒)。③多模态融合, 结合图像或语音数据, 增强多模态处理能力。④模型压缩, 采用知识蒸馏或量化技术, 降低推理时间, 适应大规模应用。

【参考文献】

- [1] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding [C]//North American Chapter of the Association for Computational Linguistics. [S. l. : s. n.], 2019.
- [2] Caruana R. Multitask learning[J]. Mach Learn, 1997, 28(1): 41-75.
- [3] ZHANG W, LI X, DENG Y, et al. Towards generative aspect-based sentiment analysis [C]//Association for Computational Linguistics. [S. l. : s. n.], 2021.

(下转第 126 页)

(性别、博士后、多机构类型等)排序靠后,影响相对有限,反映出出版与引用特征是预测总被引量的关键驱动因素。

2.3 特征选择后模型表现

在 SHAP 分析中,将排名最后的 10 个特征去除后,加入 7 个模型进行训练,结果如表 3 所示。

表 3 去除无关变量后预测模型表现

Models	MSE	MAE	R^2	MSE(cross-validation)
LR	0.278	0.333	0.714	0.274
RR	0.274	0.330	0.718	0.254
SVR	0.283	0.339	0.709	0.249
BR	0.279	0.331	0.713	0.251
RF	0.350	0.358	0.640	0.247
XGB	0.262	0.331	0.730	0.249
LGBM	0.348	0.356	0.642	0.238

注:加粗数据为最佳结果。

特征优化显著提升了 XGB 模型的性能,其 R^2 值提升至 0.730, MSE 降至 0.262, 使其成为综合表现最优的模型。所有模型的预测精度均得到了进一步提升,同时其交叉验证误差均接近或低于训练误差,表明模型具有良好的泛化性能。XGB 凭借其强大的特征筛选能力和正则化机制,在精度、稳定性和可解释性方面实现了最佳平衡,为学者总被引量预测提供了可靠的量化工具。

3 管理建议

机器学习结果表明:XGB 模型在学者总被引量预测中表现最优。在特征优化后,该模型全面领先并保持稳定误差。借助 SHAP 解释模型,除学科影响外,平均影响因子、学术年龄和主题变化被确认为推动被引量增长的三大核心因子。化学、材料科学、地理科学等学科背景具有正向效应,而最小影响因子、平均合作度等则为抑制作用。基于这些定量发现,提出以下管理建议。

(1) 构建多元学术评价体系

弱化对单一指标的过度依赖,将论文质量、主题连贯性以及学科差异等维度纳入评价框架,形成更加全面客观的学术影响力评估机制,推动科研评价从“唯论文”向“重质量”转变^[8]。

(2) 优化学科资源配置策略

基于不同学科领域的被引特征差异,科研管理部门应实施差异化的资源投入和政策支持,重点扶持具有高影响潜力的学科方向。同时,通过跨学科合作平台建设促进知识交叉融合,帮助学者在专业深耕与创新探索间找到最佳平衡点。

(3) 推进数据驱动的人才管理

运用机器学习等智能技术构建学者画像和发展潜力评估体系,为人才引进、培养和激励提供科学依据,实现从经验驱动向数据驱动的科研管理模式转变,提高人才资源配置效率和科研投入产出比。

4 结语

本文构建了一种高被引学者学术成就的系统化特征框架,从社会特征和出版与引用特征两个维度采集数据,采用 7 种机器学习算法进行对比实验。结果显示:XGB 模型取得了最佳综合表现,验证了其在捕捉复杂非线性规律方面的优势。借助 SHAP 解释机制,研究揭示,除学科影响外,平均影响因子、学术年龄以及研究方向专注度是决定总被引量的核心驱动因素。上述发现为个体学者优化科研策略提供了量化参照,也为科研管理部门在资源配置、人才评价以及个性化画像构建方面提供了可操作的技术手段。尽管研究依赖的数据存在局部缺失,但在充足样本量与稳健算法的共同作用下,所得结论仍具有实际意义。

【参考文献】

- [1] DOCAMPO D, CRAM L. Highly cited researchers: a moving target[J]. *Scientometrics*, 2019, 118(3): 1011-1025.
- [2] 赵宁,范巍,张锐昕. 中国“全球高被引科学家”结构特征和成长规律分析:基于 2014—2020 年“全球高被引科学家”榜单数据[J]. *科技管理研究*, 2022, 42(1): 208-214.
- [3] 王茜,张宓之. 全球“高被引科学家”的聚焦领域、分布格局及发展态势[J]. *科学发展*, 2022(10): 23-29.
- [4] 高芳玮,康洁雨. 顶尖科技人才科研产出特征研究:以化学领域中国大陆高被引科学家为例[J]. *化工高等教育*, 2021, 38(2): 10-15, 61.
- [5] 马荣康,李真真. 高被引还是零被引:基于论文被引的最佳科研合作规模研究——来自 Financial Times TOP 45 商学院期刊的证据[J]. *情报学报*, 2020, 39(11): 1182-1190.
- [6] RUAN X M, ZHU Y Y, LI J, et al. Predicting the citation counts of individual papers via a BP neural network[J]. *Journal of Informetrics*, 2020, 14(3): 101039.
- [7] LUNDBERG S M, LEE S I. A unified approach to interpreting model predictions[C]//*Proceedings of the 31st International Conference on Neural Information Processing Systems*. Long Beach: [s. n.], 2017: 4768-4777.
- [8] 刘红煦,唐莉. 获评高被引学者会提升学术产出与影响力吗:来自整体与个体层面的双重验证[J]. *科学学研究*, 2021, 39(2): 212-221.

(上接第 110 页)

- [4] 林娜. 基于 Bert 的层次多标签文本分类[J]. *应用数学进展*, 2024(5): 2141-2147.
- [5] 夏冰,刘斌. 一种基于 Transformer 模型进行语义分割的方法:CN118608787A[P]. 2024-09-06.
- [6] 刘欢,张智雄,王宇飞. BERT 模型的主要优化改进方法研究综述[J]. *现代图书情报技术*, 2021(1): 3-15.
- [7] ZHANG W X, LI X, DENG Y, et al. Towards generative aspect-

- based sentiment analysis [C]//*Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 2: Short Papers)*. Stroudsburg, PA, USA: ACL, 2021: 504-510.
- [8] 苟和平,景永霞,韩强. 基于 BERT 语义分析的课程评论情感分类研究[J]. *商丘师范学院学报*, 2025, 41(9): 14-17.